Diego Alejandro Escobar Barahona

Junior Data Engineer | Machine Learning Researcher | Cloud Specialist

San Salvador, El Salvador | diegoalejandroescobarahona1@gmail.com | +503 7549 0118

linkedin.com/in/diego-escobar-459256394 | github.com/bapatata688 | credly.com/badges/e27fea72-5eaf-47ee-a43c-43faa3a8fb10

Perfil Profesional

Junior Data Engineer & Investigador de ML con experiencia empresarial en **GBM (Premier Partner de IBM y Google Cloud)** y coautor en investigación científica en riesgo crediticio (OntoTab, 30,000 registros). **Google Cloud Certified Associate Data Practitioner**, con sólidas bases en arquitecturas ELT en **Google Cloud (BigQuery, Dataform SQLX, Datastream CDC)**, tareas de integración en **IBM InfoSphere DataStage, IBM DB2 LUW sobre Linux RHEL**, modelado estadístico tabular en **Python (XGBoost, Pandas, PyArrow)** y **SQL**. Bilingüe con **Inglés C1 Avanzado (EF SET 66/100, Listening C2 Proficient)**.

Investigación Científica

OntoTab: A Controlled Study of Ontology-Enriched Text for Tabular Credit Risk – *Coautor (2.º de 7), GBM* 2026

- Ejecuté los experimentos de línea base (Actividad E01) sobre un benchmark de **30,000 registros crediticios** (UCI Taiwán, 22.12% default) evaluando Regresión Logística, XGBoost y MLP bajo **validación cruzada anidada 5×3** y **2,000 iteraciones bootstrap pareadas** vía CLI.
- Analicé métricas de desempeño **respaldando el hallazgo empírico de que las representaciones numéricas estructuradas superaron a los embeddings de texto enriquecidos con ontologías en el marco experimental evaluado** (**0.5596 AP en XGBoost** frente a 0.5069 AP en representación de texto R5).

Experiencia

Data Engineer Intern (Digital Solutions Specialist), GBM (IBM & Google Cloud Premier Partner) – San Salvador Julio 2026 – Oct 2026

- Diseñé una **propuesta de arquitectura ELT** para replicación en la nube casi en tiempo real en **Google Cloud** (**BigQuery, Dataform SQLX, Datastream CDC, Cloud Storage**) entregando modelos dimensionales en **Lucidchart** y scripts **SQL DDL**.
- Desarrollé y ejecuté **tareas prácticas de integración ETL bajo mentoría técnica** en **IBM InfoSphere DataStage** (Transformers, Lookups, Joins, Merge, Funnel) sobre datasets de prueba empresariales y gestioné consultas en **IBM DB2 LUW** sobre **Linux RHEL**.
- Apoyé en la formulación de marcos de gobernanza cloud y validación presupuestaria FinOps (**IAM** de mínimo privilegio, **Service Accounts**, rotación de credenciales) y dimensionamiento de costos en **Google Cloud Pricing Calculator**.
- Desarrollé una herramienta CLI en Python bajo **Spec-Driven Development (SDD)** para compilar documentación técnica corporativa a PDF y capacité a compañeros del equipo en flujos de **Git/SSH**.

Proyectos

FERROSTATS — Data Lakehouse Medallón Cloud-Native y Pipeline Streaming en GCP GitHub | Looker Studio BI | App en Vivo

- Arquitecté un **Data Lakehouse Medallón (Bronze / Silver / Gold)** en **Google BigQuery** con **Dataform SQLX**, transformando 7 tablas raw hacia vistas Silver y **3 Data Marts Gold en Esquema Estrella** (`fct_daily_sales`, `mart_inventory_pareto_abc`, `dim_products`).
- Definí especificaciones bajo **Spec-Driven Development (SDD)** para segmentación Pareto ABC (80/20), Burn Rate y DOI, alimentando un dashboard ejecutivo de 3 páginas en **Looker Studio** con funciones de ventana analíticas.
- Construí ingesta streaming desacoplada OLTP-a-OLAP con **<50 ms** de latencia hacia BigQuery Bronze vía REST API, imponiendo concurrencia ACID e idempotencia por UUID, logrando un costo operativo FinOps permanente de **$0.00/mes en GCP** con **Cloud Run**.

Habilidades

Cloud y Data Warehouses: Google Cloud Platform (BigQuery, Dataform SQLX, Datastream CDC, Cloud Storage, Cloud Run, Artifact Registry, Looker Studio, IAM Service Accounts, Cloud Logging/Monitoring, FinOps)

Machine Learning y Modelado: Validación Anidada (5x3 Nested CV), Bootstrap Resampling, XGBoost, Regresión Logística, BGE-M3 Embeddings, Evaluación de Precisión Promedio (AP), Arquitectura Medallion

Lenguajes y Herramientas: SQL (GoogleSQL, PostgreSQL 18, Window Functions, CTEs, DDL/DML), Python 3.11 (Pandas, PyArrow, NumPy), Bash, PowerShell, Docker, Linux RHEL, Git/SSH

Idiomas: Español (Nativo), Inglés (C1 Avanzado certificado por EF SET, 66/100, Listening C2 Proficient)

Certificaciones

Google Cloud Certified — Associate Data Practitioner (Cert ID: 23e3584a246f4c149f26fea03cebcbbb) Oct 2026 – Oct 2029

Google Cloud Skill Badges: Derive Insights from Data | Prepare Data for Looker Dashboards and Reports Ago 2026

EF SET English Certificate — C1 Advanced (66/100 global • Listening 75 C2 • Speaking 69 C1) Ene 2026

Code in Place (Python Programming) — Stanford University 2026

Educación

University of the People — Pasadena, California, USA Admitted | Term 3, 2027

Bachelor of Science in Computer Science WSCUC-accredited institution | 100% Online

Bachillerato Técnico Vocacional en Desarrollo de Software – Instituto Nacional San Luis | Esperado: Dic 2026

Promedio: 9.5/10.0

- **Currículo Técnico Clave:** Lógica Algorítmica, Bases de Datos Relacionales (SQL), Estructuras de Datos, Arquitectura Web e Ingeniería de Software.